Алгоритм генерации команд восстановления дерева процессов ОС Linux на основе модели жизненного цикла ресурсов Linux

Горбунов Егор Алексеевич

научный руководитель: магистр прикладной математики и физики Е. А. Баталов

СПб АУ НОЦ НТ РАН

13 июня 2017 г.

Задача сохранения и восстановления дерева процессов

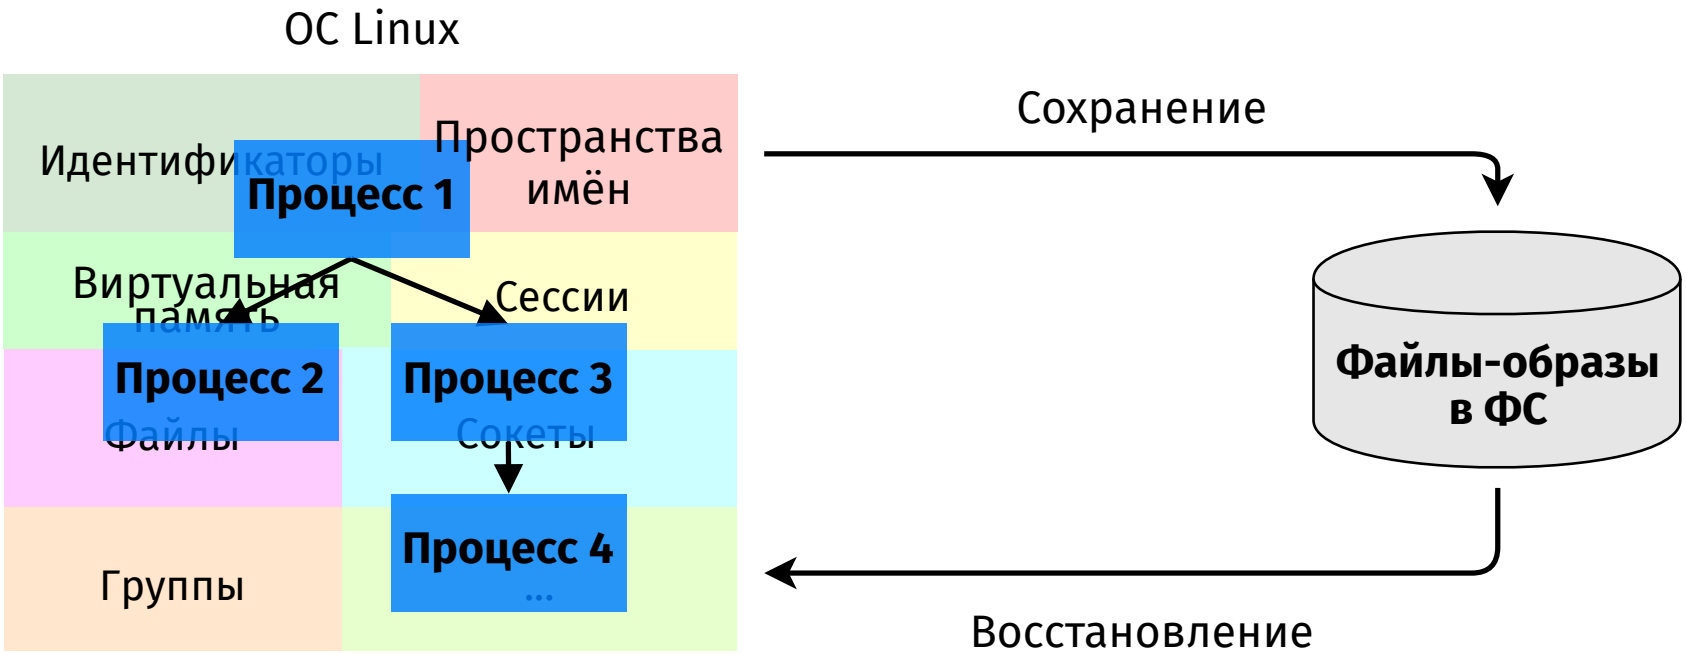

Использование

Живая миграция, ускорение запуска программ, отложенная отладка, обновление ядра без остановки программ

Существующие программные решения

- **CRIU**
  - \+ полностью в userspace
  - \+ активно поддерживается на текущий момент времени
- BLCR[1] (2003)
  - – требует загрузки модуля в ядро
- DMTCP[2] (2004)
  - – к целевому процессу с момента запуска должна быть подключена библиотека
  - – перехватывает часть вызовов к `glibc`
- OpenVZ(2005)
  - – работает внутри собственного ядра Linux

[1] Berkeley Lab Checkpoint/Restart
[2] Distributed MultiThreaded CheckPointing

Проблемы `criu` в подходе к восстановлению

Последовательность действий восстановления чётко зафиксирована в коде (и она очень большая), что приводит к проблемам:

- Код для восстановления каждого типа и зависимости ресурсов нужно аккуратно и согласованно добавить в эту последовательность $\Rightarrow$ некоторые конфигурации ресурсов не поддерживаются из-за сложности
- Фиксированный порядок восстановления $\Rightarrow$ потенциальное сужение множества допустимых деревьев для восстановления
- Отсутствие чёткого понимания того, какие конфигурации ресурсов дерева процессов `criu` гарантированно поддерживает

Подход с генератором и интерпретатором

- Для каждого конкретного дерева процессов получаем индивидуальную программу из команд
- Какие должны быть команды?
- Какие должны быть промежуточные представления?

Цель и задачи

Цель

Отойти от фиксированного порядка восстановления и найти обобщённый подход к восстановлению ресурсов

Задачи

- Разработать генератор команд для задачи восстановления дерева процессов в рамках подхода генератор-интерпретатор
- Разработать промежуточные представления

Требования

- Генерируемые команды должны быть исполнимы из пространства пользователя
- Возможность эффективной реализации предлагаемых алгоритмов

Модель дерева процессов

Ресурс — r — сущность в ядре ОС (file struct, group, session, ...)

Handle — h — объект, через который процесс получает доступ к ресурсу (file descriptor, gid, sid, ...)

Процесс

$$P = \{(r_1, h_1), (r_2, h_2), \ldots, (r_n, h_n)\}$$

$pid(P)$ — идентификатор процесса

$parent(P)$ — процесс-родитель, $\neq P$

Дерево процессов

$$T = \{P_1, P_2, \ldots, P_k\}$$

$$root = P_1$$

$$\forall P \in T \wedge P \neq root \; (parent(P) \in T)$$

Свойства ресурсов

isSharable(*r*) — ресурс, который можно разделить ”при жизни”(file, group, namespace, ...)

isInherited(*r*) — ресурс, наследуемый ребёнком ”при рождении”(file, private memory area, ...)

resourceDependencies(*r*) — множество ресурсов, от которых зависит создание *r*

Модель жизненного цикла ресурсов и процессов

Действия, которые процессы совершают при жизни:

$$\mathcal{A} = \begin{cases} ForkAction(P_1, P_2) \\ CreateAction(P, r, h) \\ ShareAction(P_{from}, P_{to}, r, h_{from}, h_{to}) \\ RemoveAction(P, r, h) \end{cases}$$

Задача восстановления

Имея исходное дерево процессов T, найти последовательность действий $[a_i]\,,\ (a_i \in \mathcal{A})$ такую, что:

$$\{P_0\} \xRightarrow{A} \{P_0\} \cup T$$

"Замыкание" исходного дерева процессов

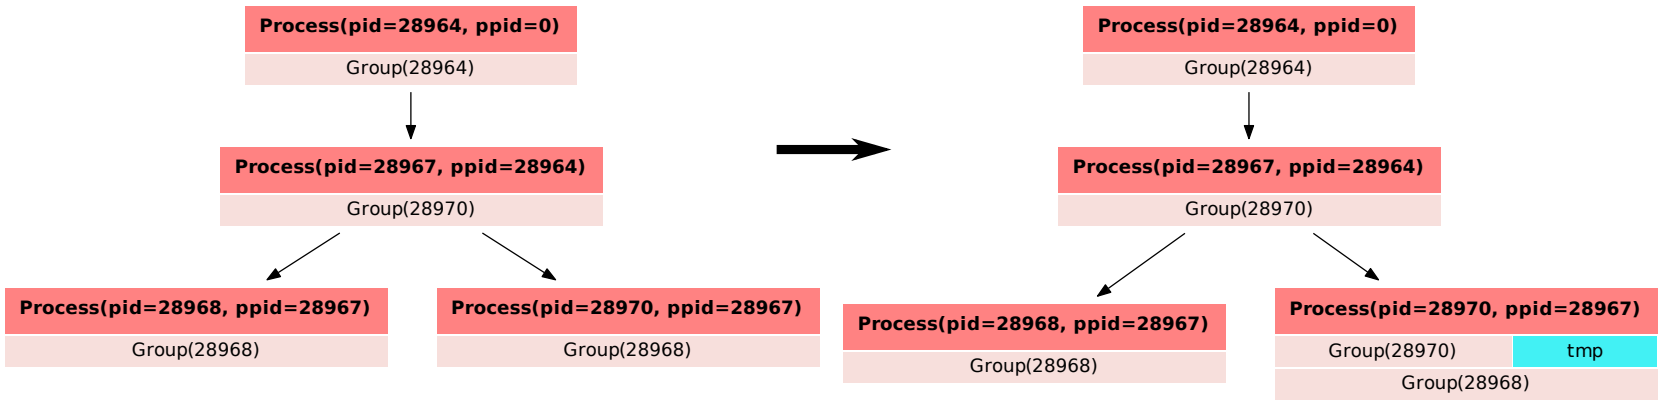

- Исходно имеем лишь снимок процесса в один момент времени
- Создание каждого ресурса *требует* определённого состояния дерева
- ”Замыкание” исходного снимка ресурсов — это объединение таких состояний
  - Полученное дерево может быть некорректным с точки зрения ОС Linux $\Rightarrow$ алгоритм должен об этом позаботиться
- Добавленные к исходному снимку процесса $P \in T$ ресурсы: $Tmp(P)$ — временные ресурсы

Построение множества действий

- Для каждого процесса $P \in T$ создаём $ForkAction(parent(P), P)$
- Для каждого ресурса r в дереве выбираем его создателя P, handle h и добавляем действие $CreateAction(P, r, h)$
- Для каждого $isSharable(r)$ ресурса, добавляем $ShareAction(P, ...)$ от создателя P к остальным процессам, держащим ресурс
- Добавляем $RemoveAction(r)$ для всех "временных" ресурсов

Построение множества действий. Пример

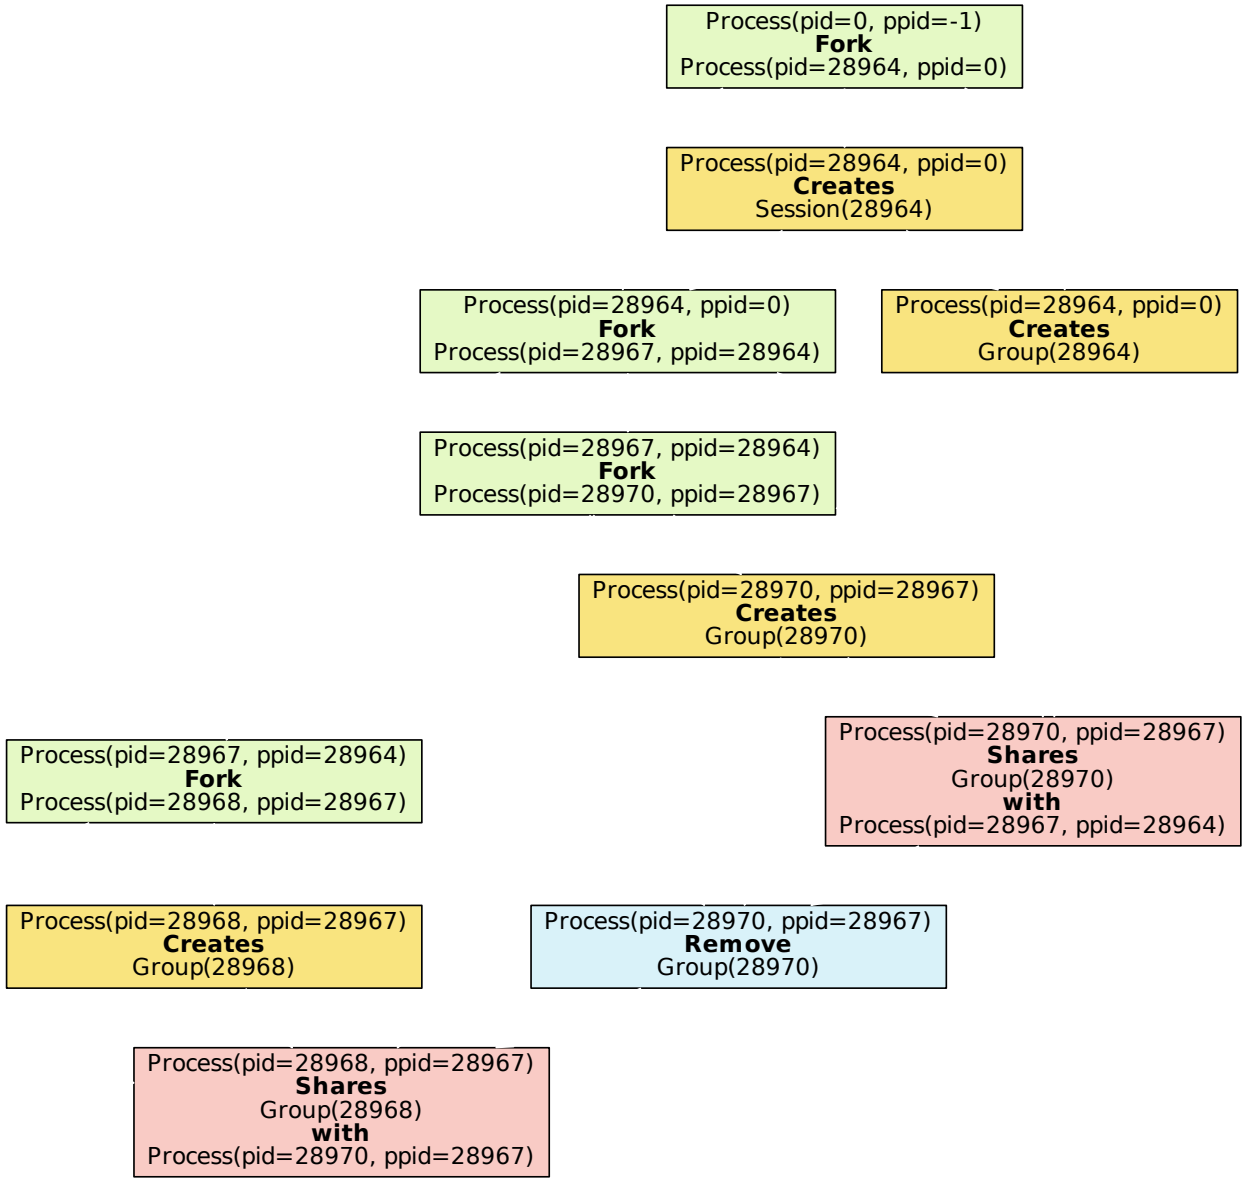

Построение рёбер предшествования

Построение ведётся в несколько этапов, каждый из которых строит часть необходимых рёбер:

- *ForkAction*$(\_, P)$ *предшествует* любому действию, которое как-то нуждается в процессе P
- *CreateAction*$(\_, r, h)$ *предшествует* любому действию, которое использует (r, h)
- Создание ресурса процессом P должно учитывать наличие зависимостей этого ресурса у процесса P
- Действия должны быть так упорядочены, что *в любой момент времени состояние дерева процессов корректно*
  - Вводим предикат *canExistTogether*(r_1, h_1, r_2, h_2) и выстраиваем рёбра так, что неудовлетворяющие ему пары не существуют одновременно
- ...

Построение рёбер предшествования. Пример

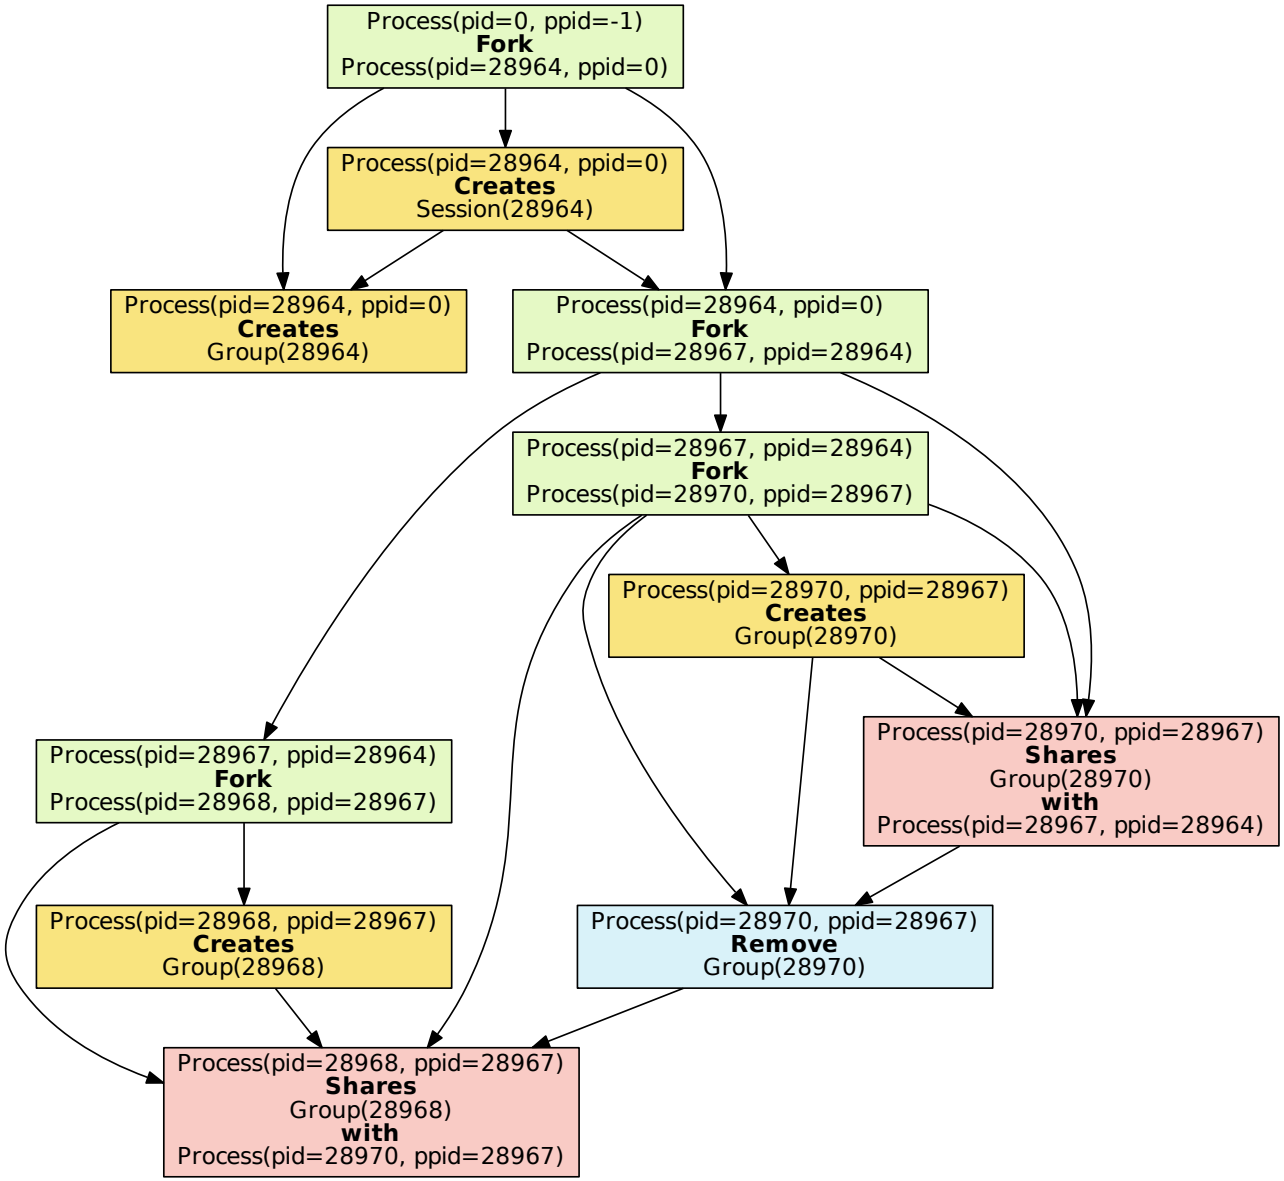

Упорядочение графа действий

- Топологическая сортировка графа + добавление недостающих действий удаления в силу наследуемых ресурсов
- Сложность всего алгоритма построения и сортировки:

$$\mathcal{O}\left(\sum_{P \in T} |P| \cdot (1 + |Tmp(P)|)\right)$$

- Если граф содержит цикл, то в рамках текущей модели восстановление невозможно

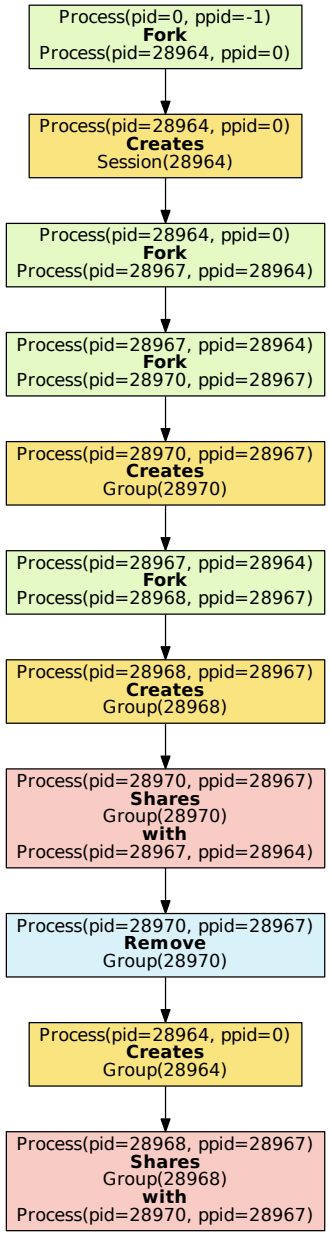

Модули генератора

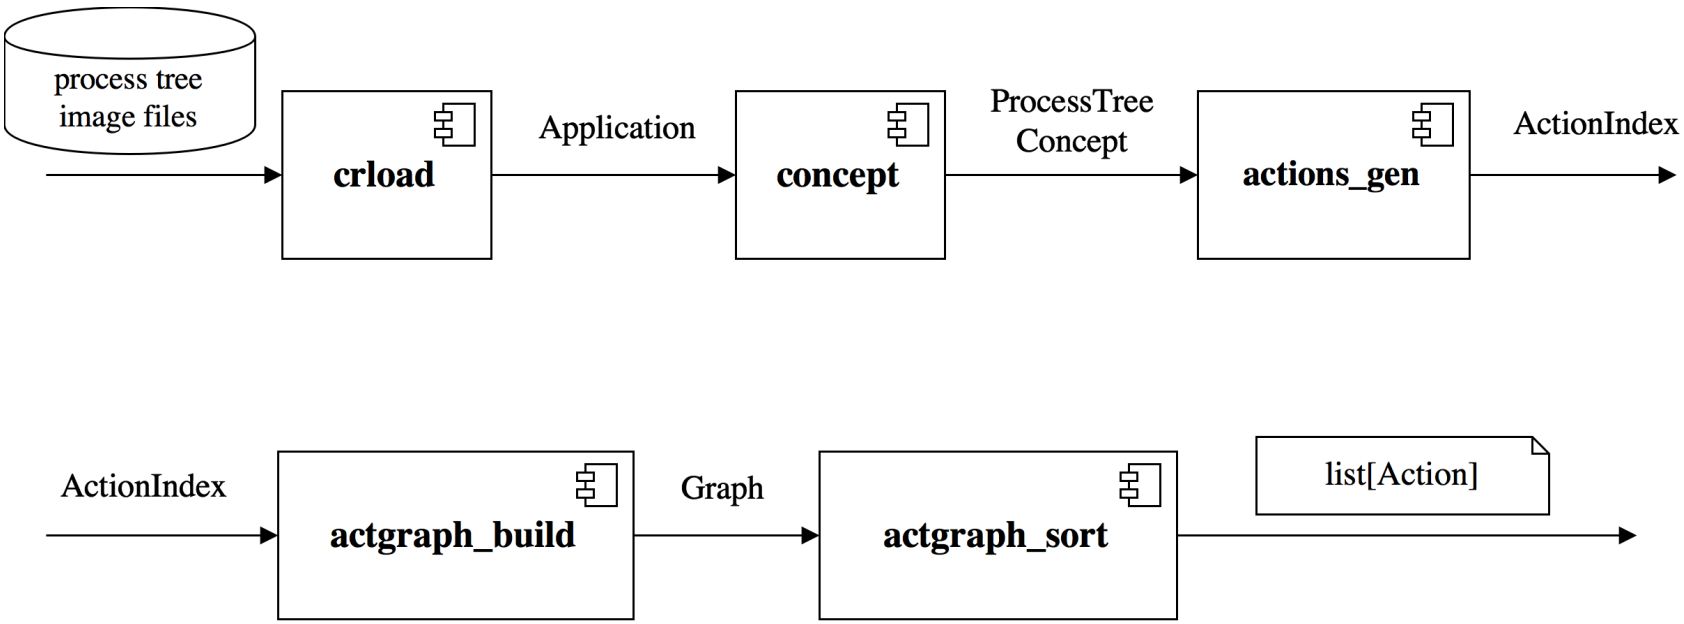

Итоги и дальнейшие планы

Итоги

- Введена формальная обобщённая модель ресурсов ОС Linux для решения задачи восстановления
- Предложен и реализован алгоритм генерации промежуточного представления в виде графа действий и последовательности действий для восстановления дерева процессов
- `https://github.com/egorbunov/criugen`

Планы

- Улучшение алгоритма для борьбы с разрешимыми циклами в графе действий
- Реализация интерпретатора команд
- Параллельное исполнение графа действий

Циклический обмен конфликтующими ресурсами

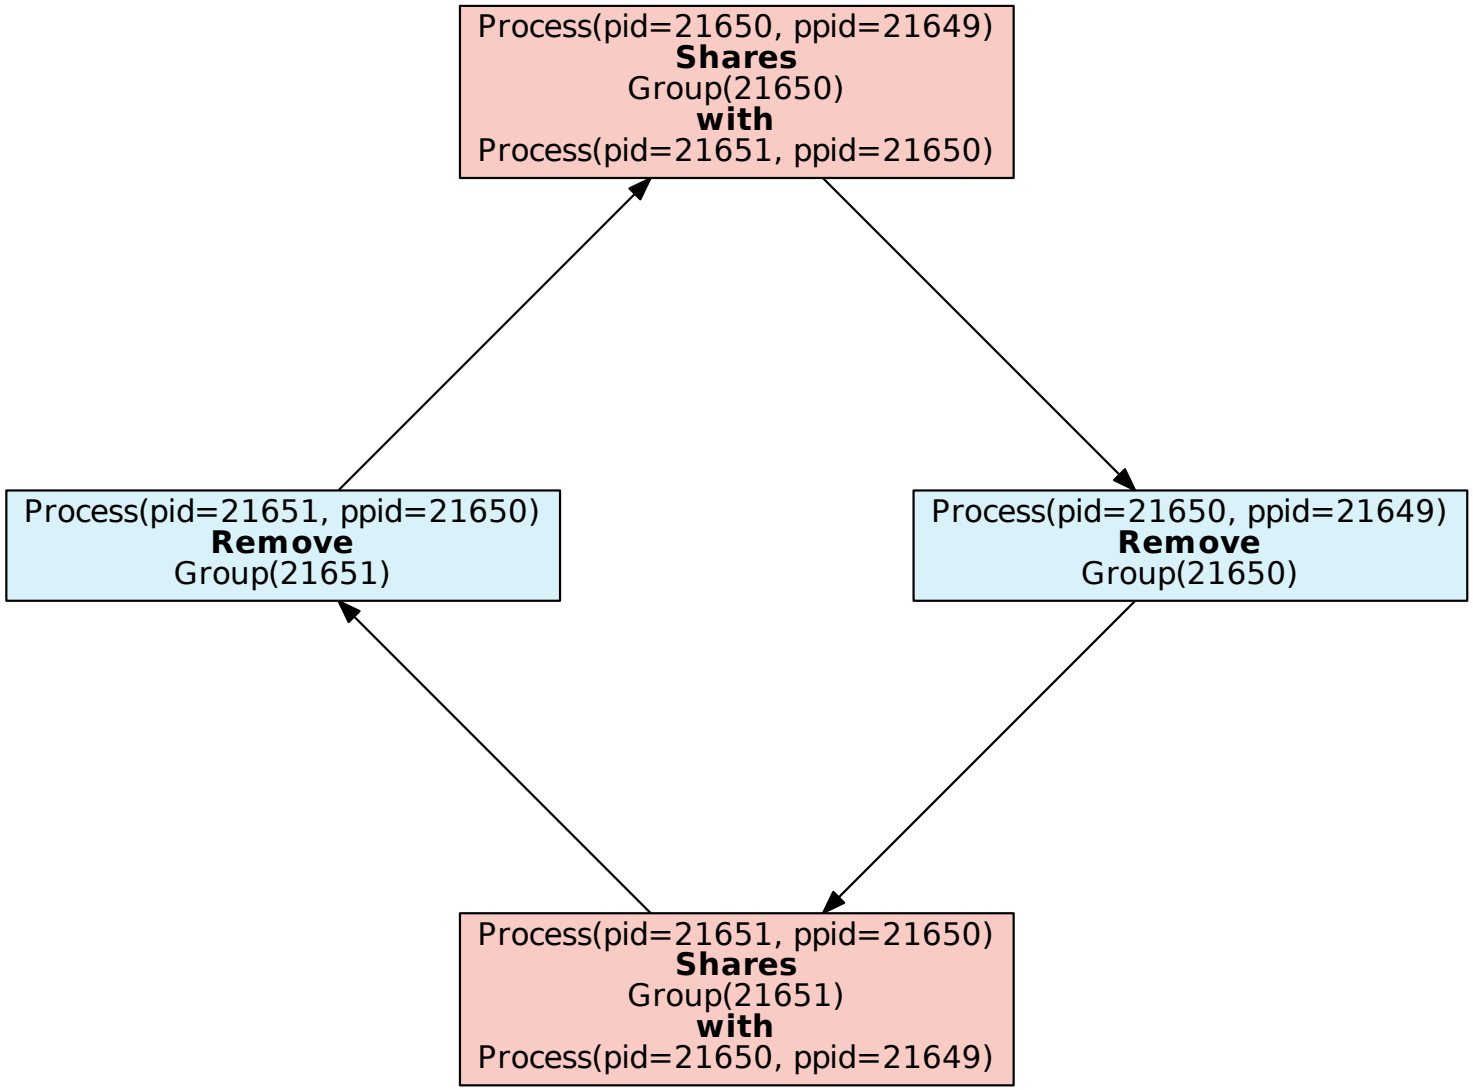

Пример с группами: дерево процессов

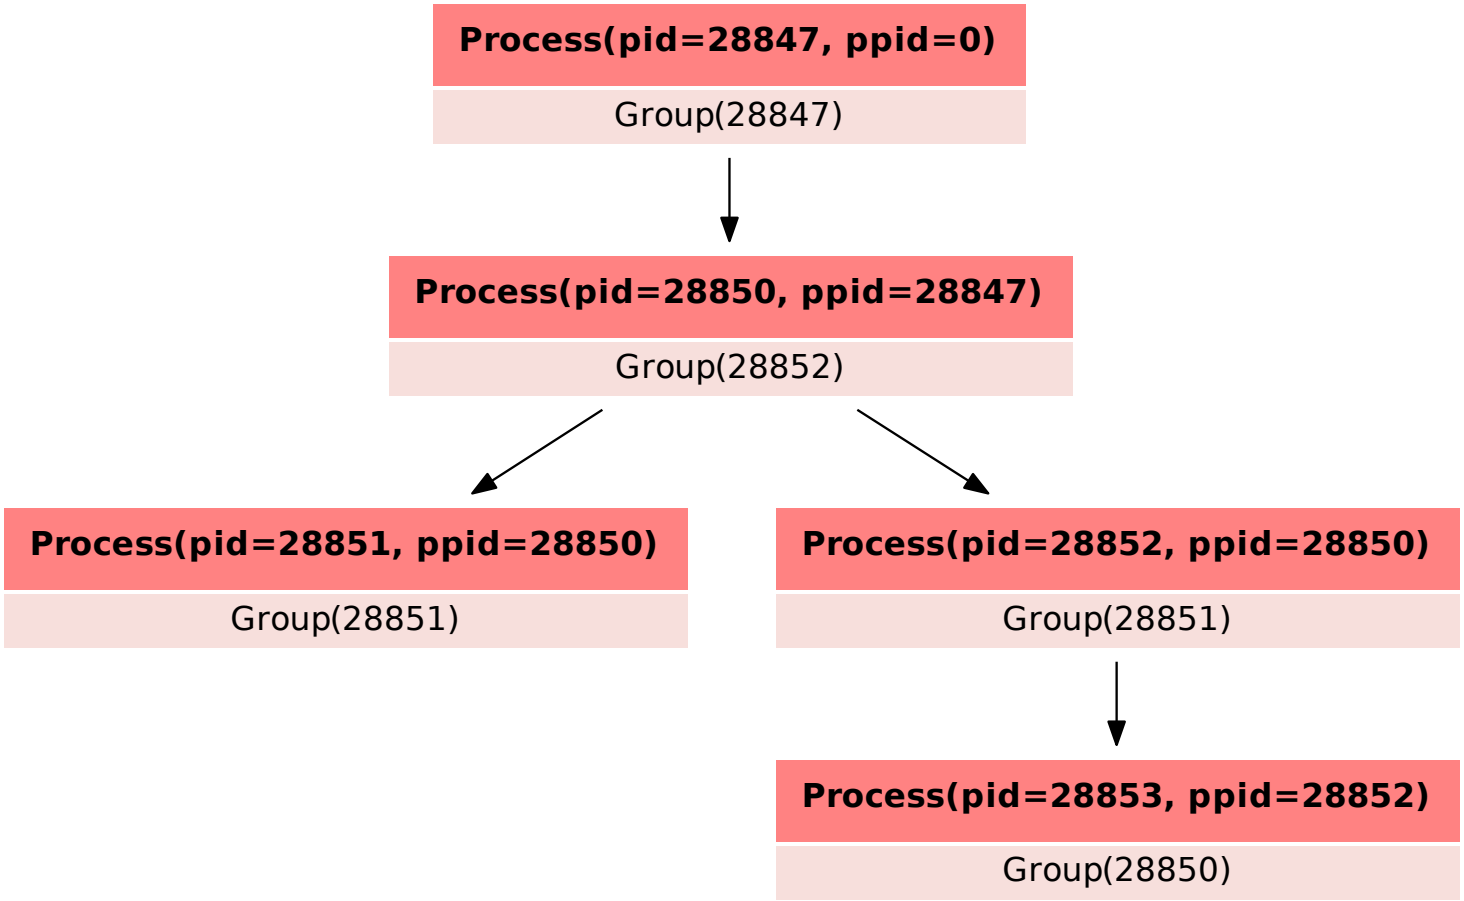

Пример с группами: граф действий

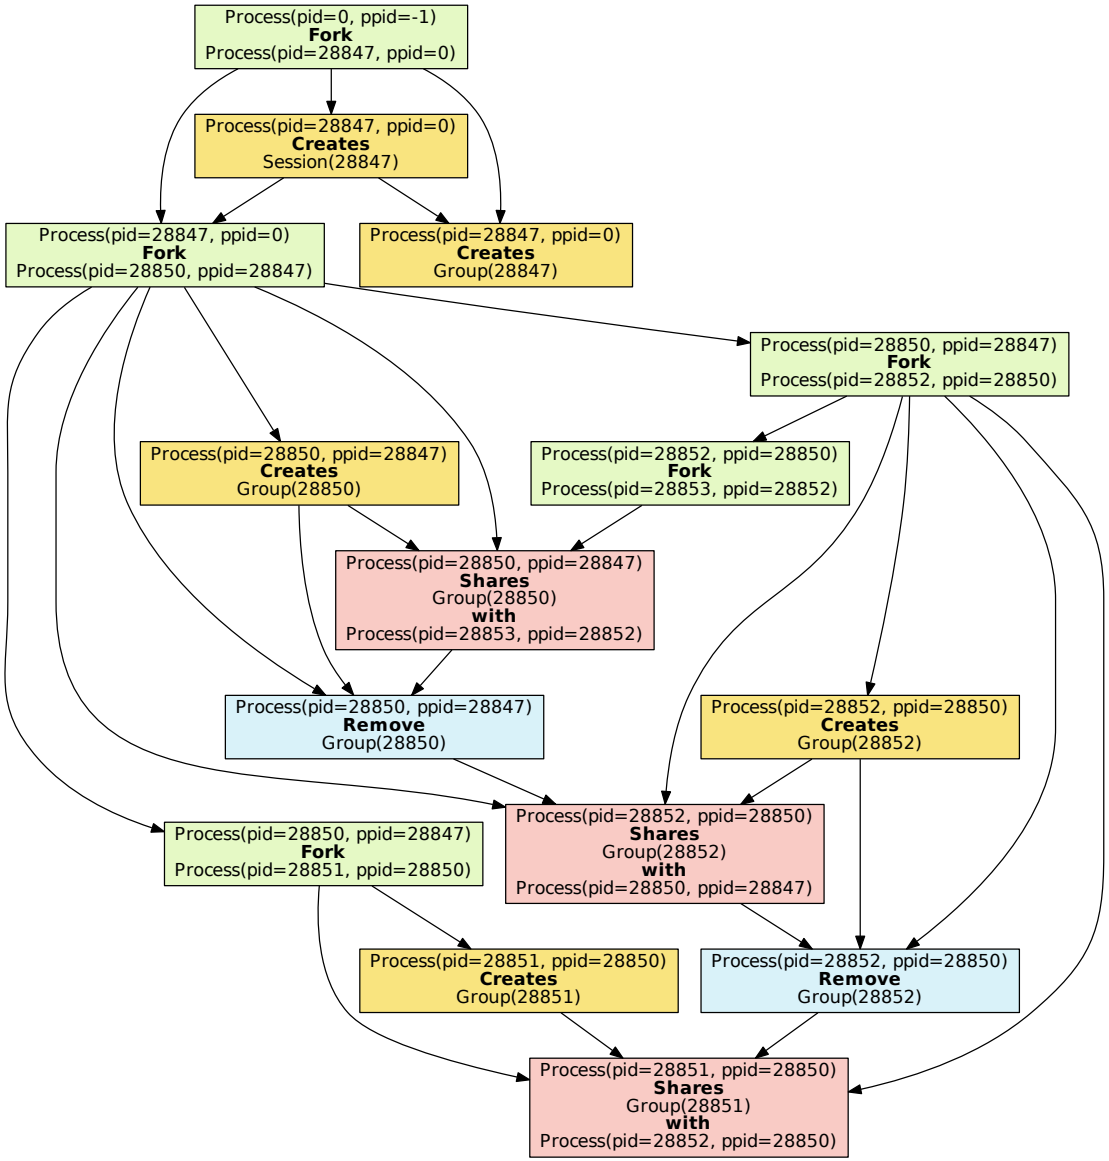

Пример с группами: упорядоченные действия

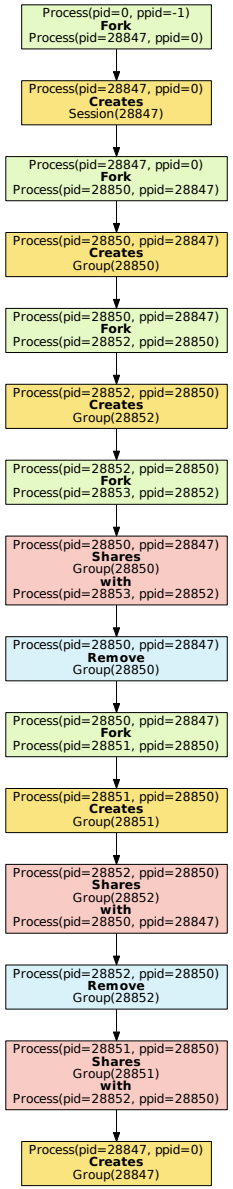

Иерархия ресурсов